

On fast optimal filtering in Gaussian switching systems.

Stéphane Derrode Clément Fernandes Frédéric Lehmann Wojciech Pieczynski

Pour $N \geq 3$, soient $X_{1:N} = (X_1, \dots, X_N)$, $Y_{1:N} = (Y_1, \dots, Y_N)$, et $R_{1:N} = (R_1, \dots, R_N)$, trois processus stochastiques. $X_{1:N}$ et $Y_{1:N}$ sont à valeurs, respectivement, dans $\mathbb{R}^q$, $\mathbb{R}^s$, et $R_{1:N}$ est à valeurs dans $\Omega = \{1, \dots, K\}$. Le problème est de calculer $E[X_n | y_{1:N}]$, pour tout $n = 1, \dots, N$.

On sait faire du filtrage et du lissage si

$$(H1) \quad (X_{1:N}, R_{1:N}, Y_{1:N}) \text{ est de Markov et homogène ;} \quad (1)$$

$$(H2) \quad p(x_{1:N}, y_{1:N} | r_{1:N}) \text{ est gaussien ;} \quad (2)$$

$$(H3) \quad p(r_{n+1} | x_n, r_n, y_n) = p(r_{n+1} | r_n) \text{ et } p(x_{n+1}, y_{n+1} | r_n, r_{n+1}) = p(x_{n+1}, y_{n+1} | r_{n+1}) \quad (3)$$

$$(H4) \quad p(r_{n+1}, y_{n+1} | x_n, r_n, y_n) = p(r_{n+1}, y_{n+1} | r_n, y_n) \quad (4)$$

Notons qu'en posant $Z_n = [X_n^T, Y_n^T]^T$, la chaîne $(R_{1:N}, Z_{1:N})$ est la très classique HMC à bruit corrélé.

Rappelons que (H4) implique markovianité de $(R_{1:N}, Y_{1:N})$, qui implique la markovianité de $p(r_{1:N} | y_{1:N})$, à l'origine de la possibilité de filtrage optimal rapide..

En fait chacune de ces hypothèses peut probablement être affaiblie, ce qui fait autant d'axes de recherche possibles. Ici on s'intéresse à (H4). (H1)–(H4) implique que les transitions sont de la forme

$$\begin{bmatrix} X_{n+1} \\ Y_{n+1} \end{bmatrix} = \begin{bmatrix} A_{r_{n+1}} & B_{r_{n+1}} \\ \mathbf{0} & D_{r_{n+1}} \end{bmatrix} \begin{bmatrix} X_n \\ Y_n \end{bmatrix} + \begin{bmatrix} U_{n+1} \\ V_{n+1} \end{bmatrix}, \quad (5)$$

et l'existence de ce zéro pose problème dans les filtrages avec les modèles à sauts.

Il s'agit donc de trouver une hypothèse différente de (H4), exploitable, qui supprimerait le zéro en question en gardant la possibilité de filtrage et lissage exacts.

Considérons (H5) (équivalente à (H) de la proposition générale, qui est $\mathbf{p}(r_n, y_n | x_{n+1}, r_{n+1}, y_{n+1}) = \mathbf{p}(r_n, y_n | r_{n+1}, y_{n+1})$) suivante :

$$(H5) \quad p(x_{n+1} | r_{n+1}, y_{n+1}, r_n, y_n) = p(x_{n+1} | r_{n+1}, y_{n+1}), \quad (6)$$

équivalent à

$$p(r_n, y_n | r_{n+1}, y_{n+1}, x_{n+1}) = p(r_n, y_n | r_{n+1}, y_{n+1}) \quad (6\text{bis})$$

Avec (H1)–(H3) et (H5) le modèle vérifie

$$\underbrace{\begin{bmatrix} X_{n+1} \\ Y_{n+1} \end{bmatrix}}_{Z_{n+1}} = \underbrace{\begin{bmatrix} A_{r_{n+1}} & B_{r_{n+1}} \\ C_{r_{n+1}} & D_{r_{n+1}} \end{bmatrix}}_{F(r_{n+1})} \underbrace{\begin{bmatrix} X_n \\ Y_n \end{bmatrix}}_{Z_n} + \underbrace{\begin{bmatrix} b_{X,r_{n+1}} \\ b_{Y,r_{n+1}} \end{bmatrix}}_{b_{r_{n+1}}} + \underbrace{\begin{bmatrix} U_{n+1} \\ V_{n+1} \end{bmatrix}}_{W_{n+1}}, \quad (7)$$

ou encore

$$Z_{n+1} = F(r_{n+1}) Z_n + b_{r_{n+1}} + W_{n+1}, \quad (7\text{bis})$$

avec

$$E[W_{n+1} W_{n+1}^T | r_{n+1}] = \begin{bmatrix} \Sigma_{U, r_{n+1}} & \Delta_{r_{n+1}} \\ \Delta_{r_{n+1}}^T & \Sigma_{V, r_{n+1}} \end{bmatrix} \quad (7\text{ter})$$

et $b_{r_{n+1}} = [b_{X, r_{n+1}}^T, b_{Y, r_{n+1}}^T]^T \in \mathbb{R}^{q+s}$ le vecteur de biais de dérive dépendant du régime ($b_{r_{n+1}} = 0$ redonne le modèle sans biais).

Rappel Dans le cas de mélange gaussien multidimensionnel $p(x, k, y) = p(k) p(x, y | k)$ on a $E[X | y] = \sum_k p(k | y) E[X | k, y]$ et $E[X_n X_n^T | y] = \sum_k p(k | y) E[X_n X_n^T | k, y]$. On peut donc calculer $E[X | y]$ et $E[X_n X_n^T | y]$ si on a les $p(k | y)$, les $E[X | k, y]$, les $E[X_n X_n^T | k, y]$, et on sait calculer les sommes. Dans le cas qui nous occupe $X = X_n$, $k = r_{1:n} = (r_1, \dots, r_n)$, et $y = y_{1:n} = (y_1, \dots, y_n)$. Le filtrage optimal sera « rapide » si on calcule $E[X_{n+1} | y_{1:n+1}]$ et $E[X_{n+1} X_{n+1}^T | y_{1:n+1}]$ à partir de $E[X_n | y_{1:n}]$, $E[X_n X_n^T | y_{1:n}]$, et y_{n+1} en un nombre fini, indépendant de n , d'opérations. L'étonnant, dû à la markovianité, est que l'on puisse le calculer pour n grand alors même que, pour m valeurs possibles de r_n , $k = m^n$.

Sachant que

$$E[X_{n+1} | y_{1:n+1}] = \sum_{r_{n+1}} p(r_{n+1} | y_{1:n+1}) E[X_{n+1} | r_{n+1}, y_{1:n+1}] \quad (8)$$

$$E[X_{n+1} X_{n+1}^T | y_{1:n+1}] = \sum_{r_{n+1}} p(r_{n+1} | y_{1:n+1}) E[X_{n+1} X_{n+1}^T | r_{n+1}, y_{1:n+1}] \quad (9)$$

Il suffit de donner le calcul de $p(r_{n+1} | y_{1:n+1})$, $E[X_{n+1} | r_{n+1}, y_{1:n+1}]$, et $E[X_{n+1} X_{n+1}^T | r_{n+1}, y_{1:n+1}]$ à partir de $p(r_n | y_{1:n})$, $E[X_n | r_n, y_{1:n}]$, $E[X_n X_n^T | y]$, et y_{n+1} en un nombre fini, indépendant de n , d'opérations.

Remarque. (H4) et (H5) impliquent que les lois marginales $p(x_n, r_n, y_n)$ de $(X_{1:N}, R_{1:N}, Y_{1:N})$ sont de la forme $p(x_n, r_n, y_n) = p(r_n) p(x_n, y_n | r_n)$, avec $p(x_n, y_n | r_n)$ gaussiennes, on dira que $(X_{1:N}, R_{1:N}, Y_{1:N})$ est « stationnaire en forme des marginales ».

1. Calcul de $p(r_{n+1}, y_{n+1} | r_n, y_n)$ et $p(r_{n+1} | y_{1:n+1})$

On sait, de par la proposition générale, que $(R_{1:N}, Y_{1:N})$ est markovien. Par ailleurs, (H2) et (H3) impliquent que

$$p(x_n, r_n, y_n, x_{n+1}, r_{n+1}, y_{n+1}) = p(r_n, r_{n+1}) p(x_n, y_n, x_{n+1}, y_{n+1} | r_n, r_{n+1}) \quad (10)$$

avec $p(x_n, y_n, x_{n+1}, y_{n+1} | r_n, r_{n+1})$ gaussienne. Il en résulte que

$$p(r_n, y_n, r_{n+1}, y_{n+1}) = p(r_n, r_{n+1}) p(y_n, y_{n+1} | r_n, r_{n+1}), \quad (11)$$

avec $p(x_n, y_n, x_{n+1}, y_{n+1} | r_n, r_{n+1})$ gaussienne. Il s'ensuit :

$$p(r_{n+1}, y_{n+1} | r_n, y_n) = p(r_{n+1} | r_n) p(y_{n+1} | y_n, r_n, r_{n+1}), \quad (12)$$

$$\text{avec } p(y_{n+1} | y_n, r_n, r_{n+1}) \sim \mathcal{N}(M_{r_{n:n+1}} y_n, \Gamma_{r_{n:n+1}}) \quad (13)$$

$$M_{r_{n:n+1}} = E[Y_{n+1} Y_n^T | r_{n:n+1}] E^{-1}[Y_n Y_n^T | r_n] \quad (14)$$

$$\Gamma_{r_{n:n+1}} = E[Y_{n+1} Y_{n+1}^T | r_{n+1}] - E[Y_{n+1} Y_n^T | r_{n:n+1}] E^{-1}[Y_n Y_n^T | r_n] E[Y_n Y_{n+1}^T | r_{n:n+1}] \quad (15)$$

Dérivation de (13)–(15) par la markovianité de $(R_{1:N}, Y_{1:N})$. Puisque $(R_{1:N}, Y_{1:N})$ est markovien homogène, la loi $p(y_{n+1} | r_n = j, r_{n+1} = k, y_n)$ est la même pour tout n ; on peut donc l'évaluer à $n = 1$ en prenant $(Z_1 | r_1 = j)$ avec sa distribution marginale, appelée *loi de bruit* : $(Z_1 | r_1 = j) \sim \mathcal{N}(0, P(j))$, avec $P(j) = E[Z_1 Z_1^T | r_1 = j]$.

De $Z_2 = F_k Z_1 + W_2$, $W_2 \perp Z_1$ sachant $(r_1 = j, r_2 = k)$, on tire $E[Z_2 Z_1^T | r_1 = j, r_2 = k] = F_k P(j)$. En posant $Y_i = [0, I] Z_i$ et $[C_k, D_k]$ la ligne Y de F_k , l'extraction des blocs Y donne :

$$\begin{aligned} E[Y_1 Y_1^T | r_1 = j] &= P_{YY}(j), \\ E[Y_2 Y_1^T | r_1 = j, r_2 = k] &= [C_k, D_k] F_k P(j) [0, I]^T = C_k P_{XY}(j) + D_k P_{YY}(j), \end{aligned}$$

d'où, par la formule du conditionnement gaussien :

$$M_{jk} = (C_k P_{XY}(j) + D_k P_{YY}(j)) P_{YY}(j)^{-1}, \quad \Gamma_{jk} = P_{YY}(k) - M_{jk} P_{YY}(j) M_{jk}^T,$$

conformément à (14)–(15) pour tout n , les blocs $P_{XY}(j)$ et $P_{YY}(j)$ étant ceux de $E[Z_n Z_n^T | r_n = j]$, fournis par les récursions (16)–(17) ci-après.

Dans le cas biaisé (option B), les covariances centrées $\Sigma(j) := P(j) - \mu(j) \mu(j)^T$ — indépendantes de n par (H4)+(H5) — remplacent $P(j)$ dans les formules ci-dessus, ce qui donne $\widetilde{M}_{jk}$ et $\widetilde{\Gamma}_{jk}$. La moyenne conditionnelle gagne en outre un terme de biais :

$$E[Y_{n+1} | r_n = j, r_{n+1} = k, Y_n = y_n] = \underbrace{[C_k, D_k] \mu_n(j) + b_{Y,k}}_{\mu_{Y,n+1}(j,k)} + \widetilde{M}_{jk} (y_n - \mu_{Y,n}(j)),$$

ce qui est exactement (13').

Les matrices de covariances $E[Y_n Y_n^T | r_n]$, $E[Y_{n+1} Y_n^T | r_{n:n+1}]$, et $E[Y_{n+1} Y_{n+1}^T | r_{n+1}]$ dans (13)–(14) sont extraites des matrices $E[Z_{n+1} Z_n^T | r_{n:n+1}]$ et $E[Z_{n+1} Z_{n+1}^T | r_{n+1}]$ — on pose $Z_n = [X_n^T, Y_n^T]^T$, voir (7bis) — calculées récursivement par

$$E[Z_{n+1} Z_n^T | r_{n:n+1}] = F_{r_{n+1}} E[Z_n Z_n^T | r_n]; \quad (16)$$

$$E[Z_{n+1} Z_{n+1}^T | r_{n+1}] = \sum_{r_n} p(r_n | r_{n+1}) F_{r_{n+1}} E[Z_n Z_n^T | r_n] F_{r_{n+1}}^T + E[W_{n+1} W_{n+1}^T | r_{n+1}], \quad (17)$$

avec

$$p(r_n | r_{n+1}) = \frac{p(r_n) p(r_{n+1} | r_n)}{\sum_{r_n} p(r_n) p(r_{n+1} | r_n)} \quad (17\text{bis})$$

et les marginales $p(r_n)$ calculées classiquement.

Remarque. Les récursions (16)–(17) supposent $\mu_n \equiv 0$ (ou, de manière équivalente, que $E[Z_n Z_n^T | r_n] = E[Z_n Z_n^T]$). Le cas général avec biais est traité dans l'option B ci-après.

Option B — moyenne non nulle. Si $\mu_n(r) := E[Z_n | r_n = r] \neq 0$, on distingue soigneusement les *seconds moments* $P_n(r_n) := E[Z_n Z_n^T | r_n]$ des *covariances centrées* $\Sigma_n(r_n) := P_n(r_n) - \mu_n(r_n) \mu_n(r_n)^T = E[Z_n Z_n^T | r_n]$. Ce sont les covariances centrées Σ_n qui remplacent les seconds moments dans toutes les formules de conditionnement gaussien.

Les moyennes marginales et les seconds moments se propagent conjointement. Pour la moyenne (récursion de la moyenne) :

$$\mu_{n+1}(r_{n+1}) = F_{r_{n+1}} \sum_{r_n} p(r_n | r_{n+1}) \mu_n(r_n) + b_{r_{n+1}}. \quad (17\text{ter})$$

Pour les seconds moments (récursion correcte, qui généralise (17) au cas biaisé) :

$$P_{n+1}(k) = F_k \left[\sum_{r_n} p(r_n | r_{n+1} = k) P_n(r_n) \right] F_k^T + F_k m_k b_k^T + b_k m_k^T F_k^T + b_k b_k^T + E[W_{n+1} W_{n+1}^T | r_{n+1} = k], \quad (17\text{quater})$$

avec $m_k := \sum_{r_n} p(r_n | r_{n+1} = k) \mu_n(r_n)$. La covariance centrée s'en déduit par $\Sigma_{n+1}(k) = P_{n+1}(k) - \mu_{n+1}(k) \mu_{n+1}(k)^T$.

Note. L'équation (17) — qui utilise $E[Z_n Z_n^T | r_n]$ des deux côtés — est incorrecte en option B car elle omet le terme de variance inter-régimes $F_k [\sum_{r_n} p(r_n | k) (\mu_n(r_n) - m_k)(\mu_n(r_n) - m_k)^T] F_k^T$. La récursion (17quater) sur les seconds moments P_n , suivie du calcul de Σ_n , évite cette difficulté et est celle implémentée dans le code. En particulier, l'équation (13) se corrige en

$$p(y_{n+1} | y_n, r_{n:n+1}) \sim \mathcal{N}(\mu_{Y,n+1}(r_{n:n+1}) + \widetilde{M}_{r_{n:n+1}} (y_n - \mu_{Y,n}(r_n)), \widetilde{\Gamma}_{r_{n:n+1}}), \quad (13')$$

où $\mu_{Y,n+1}(r_{n:n+1}) := [C_{r_{n+1}}, D_{r_{n+1}}] \mu_n(r_n) + b_{Y,r_{n+1}}$ est la moyenne de Y_{n+1} sachant $r_{n:n+1}$, et $\widetilde{M}_{r_{n:n+1}}, \widetilde{\Gamma}_{r_{n:n+1}}$ sont définis par (14)–(15) en substituant les blocs de $\Sigma_n(\cdot)$ aux blocs de $P_n(\cdot)$.

Cela termine le calcul de $p(r_{n+1}, y_{n+1} | r_n, y_n)$; $p(r_{n+1} | y_{1:n+1})$ est donné classiquement par :

$$p(r_{n+1} | y_{1:n+1}) = \frac{\sum_{r_n} p(r_n, y_{1:n}) p(r_{n+1}, y_{n+1} | r_n, y_n)}{\sum_{r_n, r_{n+1}} p(r_n, y_{1:n}) p(r_{n+1}, y_{n+1} | r_n, y_n)} \quad (18)$$

En effet :

$$\begin{aligned} p(r_{n+1} | y_{1:n+1}) &= \sum_{r_n} p(r_n, r_{n+1} | y_{1:n+1}) \\ &= \frac{\sum_{r_n} p(r_n, r_{n+1}, y_{1:n+1})}{\sum_{r_n, r_{n+1}} p(r_n, r_{n+1}, y_{1:n+1})} = \frac{\sum_{r_n} p(r_n, y_{1:n}) p(r_{n+1}, y_{n+1} | r_n, y_n)}{\sum_{r_n, r_{n+1}} p(r_n, y_{1:n}) p(r_{n+1}, y_{n+1} | r_n, y_n)} \end{aligned}$$

2. Calcul de $E[X_{n+1} | r_{n+1}, y_{1:n+1}]$ et $E[X_{n+1} X_{n+1}^T | r_{n+1}, y_{1:n+1}]$

Le calcul de $E[X_{n+1} | r_{n+1}, y_{1:n+1}]$ est immédiat à partir des identités suivantes, justifiée (en bleu) juste après le point 3 :

$$E[X_{n+1} | r_{n+1}, y_{1:n+1}] = E[X_{n+1} | r_{n+1}, y_{n+1}] \quad (19)$$

$$E[X_{n+1} X_{n+1}^T | r_{n+1}, y_{1:n+1}] = E[X_{n+1} X_{n+1}^T | r_{n+1}, y_{n+1}] \quad (20)$$

En effet, $E[X_{n+1} | r_{n+1}, y_{n+1}]$ et $E[X_{n+1} X_{n+1}^T | r_{n+1}, y_{1:n+1}]$ sont calculées simplement à partir de $E[Z_{n+1} Z_{n+1}^T | r_{n+1}]$, donnée séquentiellement par (16) et (17) :

$$p(x_{n+1} | y_{n+1}, r_{n+1}) \sim \mathcal{N}(M_{r_{n+1}} y_{n+1}, \Gamma_{r_{n+1}}),$$

avec

$$M_{r_{n+1}} = E[X_{n+1} Y_{n+1}^T | r_{n+1}] E^{-1}[Y_{n+1} Y_{n+1}^T | r_{n+1}] \quad (21)$$

$$\Gamma_{r_{n+1}} = E[X_{n+1} X_{n+1}^T | r_{n+1}] - E[X_{n+1} Y_{n+1}^T | r_{n+1}] E^{-1}[Y_{n+1} Y_{n+1}^T | r_{n+1}] E[Y_{n+1} X_{n+1}^T | r_{n+1}] \quad (22)$$

Option B. La distribution $p(x_{n+1} | r_{n+1}, y_{n+1}) \sim \mathcal{N}(M_{r_{n+1}} y_{n+1}, \Gamma_{r_{n+1}})$ ci-dessus suppose $\mu_{n+1}(r_{n+1}) = 0$. Dans le cas général, le gain de Kalman (21) utilise les blocs de la covariance centrée $\Sigma_{n+1}(r_{n+1}) = P_{n+1}(r_{n+1}) - \mu_{n+1}(r_{n+1}) \mu_{n+1}(r_{n+1})^T$, et la moyenne conditionnelle se corrige en

$$E[X_{n+1} | r_{n+1}, y_{n+1}] = \mu_{X,n+1}(r_{n+1}) + K_{r_{n+1}} (y_{n+1} - \mu_{Y,n+1}(r_{n+1})), \quad (21')$$

où $K_{r_{n+1}} = \Sigma_{XY,n+1}(r_{n+1}) \Sigma_{YY,n+1}(r_{n+1})^{-1}$, et $\mu_{X,n+1}(r_{n+1})$, $\mu_{Y,n+1}(r_{n+1})$ sont les blocs X et Y de $\mu_{n+1}(r_{n+1})$ calculé par (17ter). La formule (22) pour $\Gamma_{r_{n+1}}$ reste inchangée en substituant Σ_{n+1} à P_{n+1} .

3. Calcul de $E[X_{n+1} | y_{1:n+1}]$ et $E[X_{n+1} X_{n+1}^T | y_{1:n+1}]$ par (8)–(9) et (21)–(22)

Pour justifier (19), (20) on reprend la démonstration de la proposition 1. En posant $w_n = (r_n, y_n)$ pour tout n , on a, après l'inversion du temps (on prend $N = n + 1$) :

$$\begin{aligned} p(x_{1:n+1}, w_{1:n+1}) &= [p(w_1 | w_2) p(w_2 | w_3) \cdots p(w_{n-1} | w_n) p(w_n | w_{n+1}) p(w_{n+1})] \\ &\quad [p(x_1 | w_1, w_2, x_2) p(x_2 | w_2, w_3, x_3) \cdots \\ &\quad (x_{n-1} | w_{n-1}, w_n, x_n) p(x_n | w_n, w_{n+1}, x_{n+1}) p(x_{n+1} | w_{n+1})]. \end{aligned}$$

En intégrant par rapport à $x_1, x_2, \dots, x_n$, cela donne

$$p(x_{n+1}, w_{1:n+1}) = p(w_1 | w_2) p(w_2 | w_3) \cdots p(w_{n-1} | w_n) p(w_n | w_{n+1}) p(w_{n+1}) p(x_{n+1} | w_{n+1}),$$

qui implique $p(x_{n+1} | w_{1:n+1}) = p(x_{n+1} | w_{n+1})$, d'où (19) et (20).

En résumé, le filtrage optimal sous (H1)–(H3)+(H5) est le suivant :

Soient $p(r_n | y_{1:n})$, $E[Z_n | r_n, y_{1:n}]$, $E[Z_n Z_n^T | y_{1:n}] = E[Z_n Z_n^T | y_n]$ données (qui donnent donc également $E[X_n | r_n, y_n]$ et $E[X_n X_n^T | y_{1:n}]$). En option B, l'état inclut aussi $\mu_n(r_n) = E[Z_n | r_n]$ et $P_n(r_n) = E[Z_n Z_n^T | r_n]$ pour chaque r_n .

- (i) calcul de $E[Z_{n+1} Z_n^T | r_{n:n+1}]$ et $E[Z_{n+1} Z_{n+1}^T | r_{n+1}]$ avec (16)–(17), ensuite $p(r_{n+1}, y_{n+1} | r_n, y_n)$ avec (12)–(15), et $p(r_{n+1} | y_{1:n+1})$ avec (18); [option B : calculer $\mu_{n+1}(r_{n+1})$ par (17ter) (avec biais $b_{r_{n+1}}$), $P_{n+1}(r_{n+1})$ par (17quater), puis $\Sigma_{n+1} = P_{n+1} - \mu_{n+1} \mu_{n+1}^T$, et utiliser (13') à la place de (13)]
- (ii) calcul de $E[X_{n+1} | r_{n+1}, y_{1:n+1}]$ (qui est égal à $E[X_{n+1} | r_{n+1}, y_{n+1}]$) et $E[X_{n+1} X_{n+1}^T | r_{n+1}, y_{1:n+1}]$ (qui est égal à $E[X_{n+1} X_{n+1}^T | r_{n+1}, y_{n+1}]$) avec (19)–(22); [option B : utiliser (21') à la place de $M_{r_{n+1}} y_{n+1}$]




FIGURE 1 – Calcul récursif du filtre optimal (sous (H1)–(H3)+(H5)) et de la variance a posteriori $E[X_{n+1} X_{n+1}^T | y_{1:n+1}]$

(iii) calcul de $E[X_{n+1} | y_{1:n+1}]$ et $E[X_{n+1} X_{n+1}^T | y_{1:n+1}]$ par (8)–(9).

Finalement, l'important est les récursions (16) et (17) [et (17quater) en option B], qui permettent de calculer les lois des marginales (X_n, R_n, Y_n) et la loi de $(R_{1:N}, Y_{1:N})$. Ensuite (19) et (20) permettent de conclure.

Innovation du filtre. La récursion (i)–(iii) produit à chaque pas une quantité utile pour le diagnostic :

$$\nu_{n+1} := Y_{n+1} - \hat{Y}_{n+1|n}, \quad \hat{Y}_{n+1|n} = \sum_{r_n, r_{n+1}} \pi_n(r_n) p(r_{n+1} | r_n) E[Y_{n+1} | r_n, r_{n+1}, Y_n], \quad (\text{Inn})$$

où $E[Y_{n+1} | r_n = j, r_{n+1} = k, Y_n]$ est la moyenne conditionnelle de (13) [ou (13') en option B]. Sous le modèle exact, ν_{n+1} est une suite de variables aléatoires non corrélées (mais *non* identiquement distribuées : leur variance $S_{n+1} = \sum_{j,k} \pi_n(j) P(j, k) [\Gamma_{jk} + (\mu_{Y,jk}^{\text{cond}} - \hat{Y}_{n+1|n})(\mu_{Y,jk}^{\text{cond}} - \hat{Y}_{n+1|n})^T]$ dépend du régime courant). La densité marginale de ν_{n+1} est le mélange gaussien $p(\nu) = \sum_{j,k} w_{jk} \mathcal{N}(\nu; \tilde{\delta}_{jk}, \Gamma_{jk})$ avec $w_{jk} = \pi_\infty(j) P(j, k)$ et $\tilde{\delta}_{jk} = \mu_{Y,jk}^{\text{cond}} - \sum_{k'} P(j, k') \mu_{Y,jk'}^{\text{cond}}$ (centrage intra-régime j). En pratique on évalue la blancheur de ν par le test de Ljung–Box (sur ν_n standardisées par $S_n^{1/2}$) et la gaussianité par le test de Jarque–Bera (qui doit *rejeter* pour un GSS à séparation de régimes notable, car la densité marginale est un mélange).

0. Initialisation du filtre ($n = 1$)

La récursion (i)–(iii) démarre à $n = 1$ après réception de y_1 . Le modèle fournit, pour chaque régime $r \in \{1, \dots, K\}$:

- $\pi_0(r) = p(r_1 = r)$: distribution stationnaire de P ;
- $\mu_{z_0}(r) = E[Z_1 | r_1 = r] \in \mathbb{R}^{q+s}$;
- $\Sigma_{z_0}(r) = \text{Var}(Z_1 | r_1 = r) \in \mathbb{S}_{++}^{q+s}$.

On note les blocs de taille q et s :

$$\mu_{z_0}(r) = \begin{bmatrix} \mu_{X,0}(r) \\ \mu_{Y,0}(r) \end{bmatrix}, \quad \Sigma_{z_0}(r) = \begin{bmatrix} \Sigma_{XX,0}(r) & \Sigma_{XY,0}(r) \\ \Sigma_{XY,0}(r)^T & \Sigma_{YY,0}(r) \end{bmatrix}.$$

Le second moment initial — nécessaire pour les équations (16)–(17) — est :

$$P_{z_0}(r) := E[Z_1 Z_1^T | r_1 = r] = \Sigma_{z_0}(r) + \mu_{z_0}(r) \mu_{z_0}(r)^T = \begin{bmatrix} P_{XX,0}(r) & P_{XY,0}(r) \\ P_{XY,0}(r)^T & P_{YY,0}(r) \end{bmatrix}. \quad (\text{I.1})$$

Traitement de la première observation y_1 . La loi marginale de Y_1 sachant $r_1 = r$ est $p(y_1 | r_1 = r) = \mathcal{N}(y_1; \mu_{Y,0}(r), \Sigma_{YY,0}(r))$, d'où

$$p(r_1 = r | y_1) = \frac{\pi_0(r) \mathcal{N}(y_1; \mu_{Y,0}(r), \Sigma_{YY,0}(r))}{\sum_{r'=1}^K \pi_0(r') \mathcal{N}(y_1; \mu_{Y,0}(r'), \Sigma_{YY,0}(r'))}. \quad (\text{I.2})$$

Le gain de Kalman initial et la moyenne conditionnelle de Z_1 sachant $(r_1 = r, y_1)$ sont :

$$M_r = \Sigma_{XY,0}(r) \Sigma_{YY,0}(r)^{-1}, \quad E[Z_1 | r_1 = r, y_1] = \begin{bmatrix} \mu_{X,0}(r) + M_r(y_1 - \mu_{Y,0}(r)) \\ y_1 \end{bmatrix}. \quad (\text{I.3})$$

Les grandeurs $p(r_1 | y_1)$, $E[Z_1 | r_1, y_1]$ et $P_{z_0}(r)$ constituent l'état initial de la récursion (i)–(iii). En option B, $\mu_1(r) := \mu_{z_0}(r)$ est la valeur initiale de la récursion (17ter); la formule (I.3) est déjà la formule générale avec correction de moyenne.

4. Simulations

Attention, c'est plus une idée générale qu'une rédaction rigoureuse.

Considérons trois modèles triplets $T_{1:N} = (\mathbf{X}_{1:N}, \mathbf{R}_{1:N}, \mathbf{Y}_{1:N})$, notés M_1, M_2, M_3 , vérifiant (H1)–(H3). Leurs lois sont définies par les lois $p(r_1, r_2 |)^1$ et $p(z_1, z_2 | r_1, r_2)$. En effet, on peut, à partir de ces lois données, déterminer la présentation (7)–(7ter).

On prend les $p(r_1, r_2)$, $p(z_1 | r_1)$, et $p(z_2 | r_2)$ communes aux trois modèles, ainsi que les covariances $E[X_2 X_1^T | r_1, r_2]$, et $E[Y_2 Y_1^T | r_1, r_2]$. La différence entre M_1 et M_2 (qui sera de type « $C = 0$ ») est au niveau de $E[Y_2 X_1^T | r_2, r_1]$, et la différence entre M_1 et M_3 (qui sera le nouveau modèle proposé) est au niveau de $E[Y_1 X_2^T | r_1, r_2]$. L'idée est donc de considérer M_2 et M_3 comme des « approximations » de M_1 , et comparer leurs qualités en tant que telles.

La loi de M_1 est donc donnée par $p(r_1, r_2)$, $p(z_1 | r_1)$, et $p(z_2 | r_2)$, et

$$E_{M_1}[Z_2 Z_1^T | r_1, r_2] = \begin{bmatrix} E[X_2 X_1^T | r_2, r_1] & E[X_2 Y_1^T | r_2, r_1] \\ E[Y_2 X_1^T | r_2, r_1] & E[Y_2 Y_1^T | r_2, r_1] \end{bmatrix} \quad (4.1)$$

La loi de M_2 est obtenue à partir de (4.1) en remplaçant $E[Y_2 X_1^T | r_2, r_1]$ par $E[Y_2 Y_1^T | r_2, r_1] \mathbf{E}^{-1}[\mathbf{Y}_1 \mathbf{Y}_1^T | r_1]$

$$E_{M_2}[Z_2 Z_1^T | r_1, r_2] = \begin{bmatrix} E[X_2 X_1^T | r_2, r_1] & E[X_2 Y_1^T | r_2, r_1] \\ E[Y_2 Y_1^T | r_2, r_1] \mathbf{E}^{-1}[\mathbf{Y}_1 \mathbf{Y}_1^T | r_1] \mathbf{E}[\mathbf{Y}_1 \mathbf{X}_1^T | r_1] & E[Y_2 Y_1^T | r_2, r_1] \end{bmatrix} \quad (4.2)$$

1. On utilise ici la notation par paires (r_1, r_2) , (z_1, z_2) pour la présentation à deux pas de temps.

Et la loi de M_3 , obtenue à partir de M_1 en remplaçant l'espérance $E[Y_1 X_2^T | r_1, r_2]$ par $E[Y_1 Y_2^T | r_1, r_2] E^{-1}[Y_2 Y_2^T | r_2] E[Y_2 X_2^T | r_2]$, ce qui revient à remplacer dans (4.1) $E[X_2 Y_1^T | r_2, r_1]$ par $E[X_2 Y_2^T | r_2] E^{-1}[E[Y_2 Y_2^T | r_2]] E[Y_2 Y_1^T | r_2, r_1]$:

$$E_{M_3}[Z_2 Z_1^T | r_1, r_2] = \begin{bmatrix} E[X_2 X_1^T | r_2, r_1] & E[X_2 Y_2^T | r_2] & E^{-1}[Y_2 Y_2^T | r_2] & E[Y_2 Y_1^T | r_2, r_1] \\ E[Y_2 X_1^T | r_2, r_1] & & E[Y_2 Y_1^T | r_2, r_1] & \end{bmatrix} \quad (4.3)$$

Ainsi, en considérant le modèle « $C = 0$ » et le nouveau proposé comme deux approximations de M_1 , on pourrait évaluer laquelle est meilleure (en veillant que les deux approximations soient du « même ordre »).

Notons que (4.3) donne $F_{(r_{n+1})}$ de M_3 :

$$\mathbf{F}_{M_3, r_{n+1}} = E_{M_3}[Z_2 Z_1^T | r_1, r_2] E^{-1}[Y_1 Y_1^T | r_1]$$

On devrait donc pouvoir simuler selon M_3 et filtrer selon M_3 , et réciproquement. Ce type d'étude pourrait servir — par ailleurs — aux études du lissage.

Contrainte H5 sur les paramètres — déduction de B .

La condition (H5) impose une relation algébrique entre les 7 matrices du modèle (A , B , C , D , Σ_U , Σ_V , Δ , toutes indexées par le régime courant). En omettant provisoirement le subscript r_{n+1} , elle s'écrit :

$$\Delta^T A + \Sigma_V B^T = (\Delta^T C^T + \Sigma_V D^T) [(C \Sigma_U + D \Delta^T) C^T + (C \Delta + D \Sigma_V) D^T + \Sigma_V]^{-1} [(C \Sigma_U + D \Delta^T) A^T + (C \Delta + D \Sigma_V) B^T] \quad (4.4)$$

En réintroduisant le subscript r_{n+1} sur chacune des 7 matrices, on obtient la forme complète :

$$\begin{aligned} \Delta_{r_{n+1}}^T A_{r_{n+1}} + \Sigma_{V, r_{n+1}} B_{r_{n+1}}^T &= (\Delta_{r_{n+1}}^T C_{r_{n+1}}^T + \Sigma_{V, r_{n+1}} D_{r_{n+1}}^T) \\ &\times [(C_{r_{n+1}} \Sigma_{U, r_{n+1}} + D_{r_{n+1}} \Delta_{r_{n+1}}^T) C_{r_{n+1}}^T + (C_{r_{n+1}} \Delta_{r_{n+1}} + D_{r_{n+1}} \Sigma_{V, r_{n+1}}) D_{r_{n+1}}^T] \\ &\times [(C_{r_{n+1}} \Sigma_{U, r_{n+1}} + D_{r_{n+1}} \Delta_{r_{n+1}}^T) A_{r_{n+1}}^T + (C_{r_{n+1}} \Delta_{r_{n+1}} + D_{r_{n+1}} \Sigma_{V, r_{n+1}}) B_{r_{n+1}}^T] \end{aligned} \quad (4.5)$$

Déduction de B — système linéaire. L'équation (4.4) est *linéaire* en B^T : elle apparaît des deux membres, mais avec des coefficients matriciels connus dès que les 6 autres matrices sont fixées. On introduit les notations compactes (subscript r omis) :

$$P = \Delta^T C^T + \Sigma_V D^T, \quad Q = C \Sigma_U + D \Delta^T, \quad R = C \Delta + D \Sigma_V, \quad M = Q C^T + R D^T + \Sigma_V. \quad (4.6)$$

Remarque. $R = P^T$ (Σ_V symétrique) et $M = M^T \succeq 0$ dès que $\Sigma_U, \Sigma_V \succeq 0$. Pour avoir $M \succ 0$ (nécessaire pour inverser M et obtenir $L \succ 0$), il suffit que la covariance jointe $\begin{bmatrix} \Sigma_U & \Delta \\ \Delta^T & \Sigma_V \end{bmatrix}$ soit définie positive, ce qui équivaut à $\Sigma_V \succ 0$ et $\Sigma_U - \Delta \Sigma_V^{-1} \Delta^T \succ 0$ (complément de Schur).

L'équation (4.4) se réécrit $\Delta^T A + \Sigma_V B^T = P M^{-1} (Q A^T + R B^T + \Delta^T)$. En regroupant les termes en B^T dans le membre gauche :

$$\underbrace{(\Sigma_V - P M^{-1} R)}_L B^T = P M^{-1} (Q A^T + \Delta^T) - \Delta^T A. \quad (4.7)$$

La matrice $L = \Sigma_V - PM^{-1}R = \Sigma_V - PM^{-1}P^T$ est le *complément de Schur* de M dans la matrice-bloc symétrique $\begin{bmatrix} M & P^T \\ P & \Sigma_V \end{bmatrix}$. Si $M \succ 0$, alors $L \succ 0$ et l'unique solution est :

$$\boxed{B^T = L^{-1}(PM^{-1}(QA^T + \Delta^T) - \Delta^T A).} \quad (4.8)$$

Ainsi, dès que $A, C, D, \Sigma_U, \Sigma_V, \Delta$ sont fixées, la matrice B est *entièrement déterminée* par (4.8) : la contrainte (H5) lève le degré de liberté correspondant.

Déduction de A — système linéaire. La même équation (4.7) peut être réorganisée pour exhiber A^T comme inconnue, lorsque $B, C, D, \Sigma_U, \Sigma_V, \Delta$ sont fixées. En isolant les deux termes en A^T (celui dans QA^T à droite et celui dans $\Delta^T A^T$ qui provient de $\Delta^T A$ dans la version transposée de la contrainte) :

$$PM^{-1}QA^T - \Delta^T A^T = LB^T - PM^{-1}\Delta^T, \quad (4.9)$$

soit, en factorisant à gauche :

$$\underbrace{(PM^{-1}Q - \Delta^T)}_G A^T = LB^T - PM^{-1}\Delta^T, \quad (4.10)$$

où $G \in \mathbb{R}^{s \times q}$ et le second membre est dans $\mathbb{R}^{s \times q}$. La résolution dépend du rapport entre s et q :

- **si $s \geq q$ et G est de rang plein q** , la solution unique au sens des moindres carrés (qui annule le résidu) est :

$$\boxed{A^T = (G^T G)^{-1} G^T (LB^T - PM^{-1}\Delta^T);} \quad (4.11)$$

- **si $s < q$ ou G est rang-déficient**, A n'est pas uniquement déterminé par (H5) : il subsiste $q - \text{rg}(G) \geq 1$ degrés de liberté.

En pratique, on résout (4.10) au moyen de `numpy.linalg.lstsq` et on signale toute déficience de rang.

Déduction de Σ_U — système linéaire vectorisé. Lorsque $A, B, C, D, \Delta, \Sigma_V$ sont fixées et que l'on cherche Σ_U , le problème devient *non linéaire* dans la forme brute de (4.4) car Σ_U apparaît à la fois dans Q ($Q = C\Sigma_U + D\Delta^T$) et dans M ($M = QC^T + RD^T + \Sigma_V$ contient le terme $C\Sigma_U C^T$). On *linéarise* en multipliant (4.7) à gauche par M , ce qui élimine M^{-1} .

Posons les blocs « libres de Σ_U » :

$$Q_0 := D\Delta^T, \quad M_0 := Q_0 C^T + R D^T + \Sigma_V, \quad R := C\Delta + D\Sigma_V, \quad (4.12)$$

de sorte que $Q = Q_0 + C\Sigma_U$ et $M = M_0 + C\Sigma_U C^T$. En multipliant (4.7) par M à gauche et en regroupant les termes :

$$(M_0 + C\Sigma_U C^T)(\Delta^T A + \Sigma_V B^T) = P((Q_0 + C\Sigma_U)A^T + R B^T + \Delta^T). \quad (4.13)$$

En notant

$$Z := \Sigma_V B^T + \Delta^T A, \quad W := Q_0 A^T + R B^T + \Delta^T, \quad (4.14)$$

(tous deux de taille $s \times q$ et indépendants de Σ_U), l'égalité (4.13) se réécrit :

$$C \Sigma_U C^T Z - P C \Sigma_U A^T = \underbrace{P W - M_0 Z}_{\text{RHS} \in \mathbb{R}^{s \times q}}. \quad (4.15)$$

Pour transformer cette équation matricielle en un système linéaire standard, on utilise l'identité de *vectorisation* $\text{vec}(XYZ) = (Z^T \otimes X) \text{vec}(Y)$ (où $\otimes$ est le produit de Kronecker). En posant $E := C^T Z$ ($q \times q$) et $PC := P C$ ($s \times q$), il vient $\text{vec}(C \Sigma_U C^T Z) = (E^T \otimes C) \text{vec}(\Sigma_U)$ et $\text{vec}(P C \Sigma_U A^T) = (A \otimes PC) \text{vec}(\Sigma_U)$, d'où le système linéaire $(sq) \times q^2$:

$$\boxed{[(E^T \otimes C) - (A \otimes PC)] \text{vec}(\Sigma_U) = \text{vec}(\text{RHS})}. \quad (4.16)$$

La résolution se fait par moindres carrés ; Σ_U est ensuite *symétrisée* ($\Sigma_U \leftarrow (\Sigma_U + \Sigma_U^T)/2$) puis on vérifie sa *définie-positivité* par décomposition de Cholesky.

Bilan. La contrainte (H5) lie les sept matrices $(A, B, C, D, \Sigma_U, \Delta, \Sigma_V)$ d'un même régime par une seule équation matricielle. Selon la matrice que l'on considère comme inconnue :

Inconnue	Système (équation)	Existence/unicité
$\overline{B}$	$L \overline{B}^T = \text{rhs}_B \quad (4.7)$	unique si $L \succ 0$
A	$G A^T = \text{rhs}_A \quad (4.10)$	unique si $\text{rg}(G) = q$
Σ_U	Kronecker $(sq \times q^2) \quad (4.16)$	unique si $\text{rg} = q^2$, puis SPD

Les trois projections sont implémentées dans `prg/utils/h5_constraint.py` (`compute_B_from_h5`, `compute_A_from_h5`, `compute_SU_from_h5`), avec contrôle de conditionnement et levée d'exception en cas de système mal posé.